

내부 RAG 세무 근거 검색 파이프라인

실무서를 통째로 외우게 하는 게 아니라, 인용 가능한 근거만 찾아 쓰는 ②번 채널

docs / 05_내부RAG.md → 비개발자(KICPA)용 도식 해설

 10단계 파이프라인 · 문서유형별 청킹

 하이브리드 검색(의미+키워드) + 재랭킹

 공유 vs 고객 인덱스 격리

작성 · 신현우 (KICPA, 2년차)

목적 · 딜로이트 안진 Business Tax 지원 / 포트폴리오

문서 · 법인세 자문 보조 AI 설계서 — 내부 RAG 章 해설본

날짜 · 2026-06-28

30초 요약 — 내부 RAG가 뭐죠?

한 문장: AI에게 우리 실무서·예규·내부 검토메모를 전부 외우게 하는 게 아니라, 질문이 들어올 때 관련된 근거 조각만 찾아와 인용하게 만드는 장치입니다. 세 근거(①법령MCP ②내부RAG ③웹) 중 ②번 채널로, 자기 몫의 독립 답변을 만듭니다.

① 무엇을 하나

자료를 문서유형에 맞게 잘라 색인하고, 질문에 맞는 chunk만 검색·재정렬해 인용 달린 답을 만듭니다.

② 왜 어려운가

법령·예규·메모는 구조가 제각각이라 한 가지 방법으로 자르면 인용이 깨집니다. 게다가 토큰 비용·고객 격리까지 통제해야 합니다.

③ 무엇이 아닌가

최종 결론을 내는 채널이 아닙니다. ②번 독립 답변(SourceAnswer)을 만들고, 종합은 별도 단계에서 합니다.

회계사의 직관으로 번역하면 — 3가지 비유

비유 1 · AI 전용 「조서실 + 색인카드」

방대한 자료를 AI에게 전부 외우라고 하지 않습니다. 질문이 오면 관련 조서철과 근거 위치를 빠르게 찾아주는 색인 체계를 둡니다. 핵심은 "다 집어넣기"가 아니라 "필요한 근거만 정확히 꺼내기".

비유 2 · 「조서 유형별 파일링 기준」

감사조서도 유형마다 정리법이 다르죠. 여기서도 법령은 조문 단위, 예규는 사실관계·회신요지 단위, 내부 검토메모는 쟁점·의견·근거 단위로 다르게 잘라야 나중에 그 조각을 정확히 인용할 수 있습니다.

비유 3 · 「고객별 독립 보관함」

공용 법령 자료와 고객 비밀자료는 같은 검색창에서 찾더라도 저장소와 접근권한은 분리돼야 합니다. A사 자료가 B사 답변에 새면 안 됩니다(교차 회수 0건).

💡 사용자 핵심 질문에 대한 답

"text split·임베딩·벡터DB도 내가 직접?" → 그렇습니다. 단 '직접 통제'와 '직접 구현'은 다릅니다. 분할 전략·임베딩 모델 선택·검색 설계·품질기준은 직접 설계(통제)하고, 벡터DB 엔진 자체는 기성품을 씁니다.


도식 ① — 내부 RAG 10단계 파이프라인

자료가 들어와 답변 근거가 되기까지 **10단계**. 앞 6단계는 미리 쌓아두는 **적재(오프라인)**, 뒤 4단계는 질문이 올 때
도는 **질의(온라인)**입니다.

■ 적재 (오프라인) — 미리 쌓아둠



■ 질의 (온라인) — 질문이 올 때



코드 위치 (Workpaper 2120)

- `src/` — 분할·검색조립·로깅 (결정적 로직)
- `src.ai/` — 임베딩·LLM·reranker 호출 (어댑터)
- `contract/` — Chunk·RetrievalRun 스키마
- 벡터 데이터·로그 — 런타임(`runs/`)

💡 왜 ③번(구조분할)이 핵심인가

법령을 문단 길이로 자르면 **조문 경계가 깨져** 인용이
무너집니다. 세무 RAG의 성패는 **"무엇을 어떻게 자
르느냐"**에 달려 있습니다(다음 페이지).

도식 ② — 문서유형별 청킹: 똑같이 자르면 망한다 핵심

이章의 가장 중요한 결정. 문서유형마다 잘리는 기준이 다르고, 각 조각에 인용 메타(조문번호·시행일 등)를 박습니다.

문서유형	분할 기준 (어떻게 자르나)	조각에 박는 인용 메타
법령	조 > 항 > 호 > 목 단위 + 부칙·경과조치·별표·서식은 별도 위치로	법령명·조문번호·공포일·시행일·부칙 적용 근거
시행령/규칙	조문 + 위임관계(상위 법 조문)	위임 법조문·시행일
예규/질의회신	사실관계·질의·회신요지·관련법령·판단근거 섹션 (실제 자료는 섹션명 불규칙·복수질의 → 정규화+분할)	문서번호·issued_date·issuer·질의별 분리
판례/심판례	사건번호·쟁점·판단·결론	법원·선고일·인용 조문
내부 검토메모	쟁점·검토의견·근거·결론	검토자·검토일·관련쟁점
실무서	장/절 + 의미 경계(semantic)	출처·페이지·판수(edition)
회사 재무자료	행/열 구조 추출(청킹 아님 — TB·원장)	계정과목·거래처·금액·기간·증빙유형
계약서	조항(article) 단위	조항번호·당사자·일자

자르기 규칙

- 구조 경계 > 토큰 길이: 길이보다 조문·조항 경계를 우선.
- 작은 조문은 병합, 긴 조문은 항 단위 분할 + 부모 조문 참조.
- 실무서만 토큰 기준(512~1,024) + 10~15% overlap.

💡 회계사 포인트

감사조서를 **유형별로 다르게 편철**하는 것과 같습니다. "회신요지만 따로 꺼내기", "부칙만 따로 찾기"가 가능하려면 **처음 자를 때부터** 구조를 살려야 합니다.

RAG-001~003·015~017

도식 ③ — 하이브리드 검색 + 재랭킹: 두 방식을 합친다

의미검색 하나로는 부족합니다. 의미(벡터)검색 + 키워드(BM25)검색을 합치고, 필터로 좁힌 뒤 정밀 재정렬합니다.



재랭킹 점수 신호 (소스 내부 스코어링)

- 본문 유사도 + 출처 신뢰도(authority_rank)
- 문서유형 + 제목·귀속연도 일치
- 적용시점 유효성 (그 사업연도에 유효한 버전)

※ 소스 간 가중혼합이 아니라, ②번 채널 내부의 후보 정렬 기준입니다.

⚠ "최신" ≠ "정답"

세무는 가장 최신 법령이 아니라 그 사업연도에 유효했던 버전이 정답입니다. 그래서 최신성 점수와 적용시점 유효성 점수를 분리하고, 시점 위배 버전은 강등·배제합니다. RAG-005

💰 토큰 비용 통제 (실무서를 통째로 안 넣는 법)

① top-k만

관련 chunk 몇 개만 회수

② 압축

질의 관련 문장만 추출

③ 질의 분해

하위질의별 소량 회수

+ 부모 확장은 필요 시에만, 동일 쟁점·시점 재질의는 캐시. RAG-009·010 • NFR-001

도식 ④ — 공유 인덱스 vs 고객 인덱스 분리 ("split embedding DB"의 실체)

검색 저장소를 두 종류로 물리·논리 분리합니다. 공용 법령지식과 고객 비밀자료가 절대 섞이지 않게.

■ 공유 참조 인덱스 (읽기 전용)

- 법령 · 예규 · 판례 · 라이선스 실무서
- 등급 L0~L2 (공개·라이선스·합성)
- 모든 매터가 공통으로 참조

■ 테넌트 인덱스 (client별 파티션)

- 고객 자료 (원장·계약·검토메모 등)
- 등급 L3~L4 (수임범위 내 기밀)
- **client_id로 칸막이** — 끌 수 없는 격리필터



⊗ 격리는 옵션이 아니라 기본 통제

테넌트 필터는 검색 단계에서 끌 수 없습니다. "필터를 빠뜨릴 수 있는 구조" 자체를 금지하고, 공유 인덱스와 고객 인덱스를 물리·논리로 분리합니다. 교차 회수 0건이 합격선입니다. RAG-007 · SEC-002/003

도식 ⑤ — 인용 추적: 답변 문장에서 원문까지 거꾸로 간다

답변의 어떤 문장이든 그 근거가 된 원문 조문/문단까지 역추적할 수 있어야 합니다. = 감사조서의 cross-reference.



각 조각(Chunk)에 박는 인용 필드

`doc_type` · `authority_rank` · 법령명/문서번호 ·
`source_locator`(조/항/호 구조 필드) · 공포일·시행일
· `amended_by`(개정이력) · `tax_type` · 귀속연도 ·
`client_id` · `content_hash`

→ 인용 검증(08 G2)이 `pinpoint`·시점까지 기계로 대조 가능.
RAG-006·017

💡 왜 URL이 아니라 객체인가

"법 OO조" 링크만으론 부족합니다. 조·항·호·목 + 시행일 + 개정이력까지 박힌 버전 객체를 가리켜야
"어느 시점의 어느 조문으로 판단했는지"가 재현됩니다(자세히는 02_출처).

📄 RetrievalRun 로깅 (재현성)

질의·하위질의·필터·후보 `chunk_id`·재랭킹 점수·최종 채택을 전부 기록합니다. 나중에 "이 답이 어떤 근거에서 나왔나"를 100% 복원. RAG-013 · SEC-007

도식 ⑥ — 두 가지 정밀장치: 부모-자식 회수 · 적용시점 필터

(1) Parent-Child Retrieval — 작게 찾고, 크게 답한다

작은 조각으로 정확히 검색하되, 답변에는 부모(조문 전체·예규 전체)를 함께 줘서 맥락 손실을 막습니다.



(2) 적용시점 유효성 필터 — "그 사업연도에 유효한 버전"

같은 조문도 개정 전후로 내용이 다릅니다. 적용시점에 유효한 버전만 검색 후보에 넣습니다.



💡 두 장치의 공통점

둘 다 "정확히 찾되, 틀린 맥락·틀린 시점으로 답하지 않게" 하는 안전장치입니다. 회계사가 해당 연도 세법으로, 조문 전체 맥락에서 판단하는 습관을 전산화한 것입니다.

비개발자를 위한 전문용어 사전

내부 RAG에 자주 나오는 기술 용어를 회계사 눈높이로 한 줄씩 풀었습니다.

RAG Retrieval-Augmented Gen.	AI가 우리 자료를 검색해 근거로 답하게 하는 기법. 기억만으로 답하지 않게 자료실을 붙여줌.
청킹 Chunking	긴 문서를 AI가 찾기 쉬운 작은 근거 단위로 나누는 작업.
구조인식 분할 Structure-aware Split	문단 길이가 아니라 조문·질의·회신·쟁점 같은 문서 구조에 맞춰 나누는 방식.
임베딩 Embedding	문서 내용을 숫자 좌표로 변환해 의미가 비슷한 자료를 찾게 하는 처리.
벡터 DB Vector DB	임베딩 값을 저장하고 의미 기반 검색을 수행하는 데이터베이스. 엔진은 기성품 사용.
하이브리드 검색 Hybrid Search	의미검색 + 키워드검색을 함께 써서 누락을 줄이는 검색.
BM25 키워드 검색	조문번호·세목·고유명사처럼 정확한 단어 매칭에 강한 전통 검색 방식.
재랭킹 Rerank	1차 검색 결과를 적합도·권위·시점 기준으로 다시 정렬하는 단계.
부모-자식 회수 Parent-Child	작은 단위로 찾은 뒤 상위 문맥(조문 전체)을 함께 가져와 오해를 줄이는 방식.
테넌트 인덱스 Tenant Index	고객별 자료가 섞이지 않도록 분리한 전용 검색 저장소.
RetrievalRun 검색 로그	어떤 질문에서 어떤 근거가 검색·선택됐는지 남기는 감사 로그(재현성).
SourceAnswer 소스별 독립 답변	①②③ 각 채널이 따로 낸 완결 답변. 내부 RAG는 ②번을 책임.

흔한 오해 8 — "이렇게 말하면 틀립니다"

내부 RAG를 소개할 때 자주 빠지는 함정입니다. 오른쪽이 정확한 설명입니다.

#	❌ 이렇게 말하면 틀림	✅ 정확히는	근거
1	"RAG를 붙이면 환각이 끝난다"	RAG는 근거 후보를 찾는 장치. 근거 부족 시 abstain ·검증이 따로 필요.	RAG-014
2	"청킹은 적당한 길이로 자르면 된다"	세무 자료는 유형별 구조가 달라 문서유형별 분할 이 필수.	RAG-001~003
3	" Vector DB 만 있으면 검색은 충분"	조문번호·세목은 BM25 키워드검색 이 필수(하이브리드).	RAG-008
4	"최신 자료가 항상 정답이다"	세무는 해당 사업연도에 유효한 버전 이 우선.	RAG-005
5	"고객자료도 공용 인덱스에 넣으면 편하다"	고객 자료는 테넌트 인덱스 로 격리. 교차 회수 0.	RAG-007
6	"인용은 원문 링크만 있으면 된다"	조문·문단· 시행일 · 개정이력 까지 추적 가능해야.	RAG-006/017
7	"임베딩 모델은 한 번 고르면 끝"	버전 변경 시 재임베딩 ·인덱스 버전관리 필요.	RAG-011
8	"내부 RAG가 최종 답을 만든다"	독립 SourceAnswer(②) 를 생산. 결론은 통합 단계.	RAG 11절

한 문장으로 안전하게

"내부 RAG는 법령·예규·내부자료를 문서유형별로 구조화해 두고, 질문에 맞는 인용 가능한 근거만 찾아 ②번 독립 답변을 만드는 세무 근거 검색 파이프라인입니다. 최종 결론은 종합·회계사 몫입니다."

이 장을 왜 이렇게 썼나 — 핵심 메시지 3

01 핵심은 "문서를 넣기"가 아니라 "근거를 감사 가능한 단위로 쪼개 추적"

법령은 조문, 예규는 회신요지 단위로 **다르게 잘라** 조각마다 **조문번호·시행일**을 박습니다. 그래야 답변의 모든 문장을 **원문까지 역추적**할 수 있습니다.

02 의미검색만으로는 부족 — 조문번호·시점·권위·고객격리를 함께 통제

의미+키워드 하이브리드로 찾고, 적용시점 유효성으로 거르고, 테넌트 격리로 칸막이. "직접 통제(전략·검색설계)"하되 "벡터DB 엔진은 기성품"을 씁니다.

03 내부 RAG는 최종 결론자가 아니라 "독립 ② SourceAnswer 채널"

회수된 근거 **안에서만** 답하고, 근거 부족·충돌·시점 불명이면 **단정 대신 검토항목**으로. 종합과 최종 판단은 별도 단계·회계사 몫입니다.

면접 한 줄

"RAG를 '문서 잘라 벡터DB에 넣기'로 보면 세무에선 실패합니다. 법령은 조문 단위, 예규는 회신요지 단위로 **다르게 잘라야** 하고, chunk마다 **조문번호·시행일**을 박아야 인용이 삽니다. **split 전략·임베딩 선택·검색 설계는 직접 통제**하고 벡터DB 엔진만 기성품을 쓰며, 실무서를 통째로 안 넣고 **관련 chunk만 회수**해 토큰 비용을 잡습니다."