

웹 리서치 ● 최신 공식근거 수집기

"답을 만드는 검색"이 아니라, 국세청·기재부·법제처 공식 원문을 찾아오는 ③번 독립 채널

docs / 06_웹리서치.md → 비개발자(KICPA)용 도식 해설



발견(Discovery) vs 권위(Authority) 2계층



Source Policy 이중 필터 (검색 전·후)



충돌 시 결론 보류 (ConflictFlag)

작성 · 신현우 (KICPA, 2년차)

목적 · 딜로이트 안진 Business Tax 지원 / 포트폴리오

문서 · 법인세 자문 보조 AI 설계서 — 웹 리서치 章 해설본

날짜 · 2026-06-28

30초 요약 — 웹 리서치가 뭐죠?

한 문장: 인터넷 검색으로 답을 만드는 장치가 아니라, 개정 동향·신규 예규·보도자료 같은 **최신 근거**를 국세청·기재부·법제처 공식 원문에서 찾아와 ③번 독립 답변(SourceAnswer)을 만드는 수집·검증 채널입니다. 검색엔진은 단서를 찾는 발견 도구일 뿐, 결론 근거는 공식 원문으로 승격(promote)된 것만 씁니다.

① 무엇을 하나

쟁점을 받아 공식 출처에서 최신 근거 후보를 찾고, 원문을 추출·검증해 ③번 독립 답변을 만듭니다.

② 무엇이 아닌가

답을 '생성'하는 곳이 아닙니다. 결론은 종합 단계에서, 웹 단독 세무 단정은 금지.

③ 핵심 원칙

검색=발견, 근거=공식 원문 승격분만. 법령(①)·내부RAG(②)와 충돌 시 보류.

회계사의 직관으로 번역하면 — 3가지 비유

비유 1 · 「공식출처 우선 조사절차」

어떤 쟁점을 조사할 때 **블로그 검색 결과를 그대로 답으로 쓰지 않습니다**. 국세청·기재부·법제처·법원 원문을 직접 찾아 '증거능력'을 확인하죠. 웹 리서치가 바로 그 절차입니다 — 검색은 어디를 볼지 알려주는 길잡이, 인용은 공식 원문에서.

비유 2 · 「단서(제보) vs 감사증거」의 구분 = Discovery vs Authority

감사에서 **제보·소문(단서)**과 **감사증거**는 다릅니다. 단서로 어디를 볼지는 정하되, 결론은 입수한 증거로만 냅니다. Tavily·Brave는 단서, 결론 근거는 공식 원문으로 승격된 것만.

비유 3 · 「증거 채택 기준표」 = Source Policy

감사조서에 아무 자료나 첨부하지 않듯, **블로그·카페·요약글은 채택 기준에서 배제**합니다. 어떤 출처를 근거로 인정할지 **미리 정한 기준표**가 Source Policy입니다.

💡 핵심 한 줄

웹 리서치의 산출물은 '답'이 아니라 '검증된 최신 공식근거 후보'입니다. 답을 만드는 건 **종합(Synthesis)**이고, 최종 판단과 서명은 **회계사**입니다.

도식 ① — 두 계층: 발견(Discovery) vs 권위(Authority)

웹 리서치에서 가장 중요한 구분. 검색엔진은 단서를 찾는 발견 도구일 뿐, 그 자체로 근거가 아닙니다. 결론 근거가 되려면 공식 원문으로 승격(promote)돼야 합니다.

① 발견 계층 (Discovery) — "어디를 볼지 찾는 곳"

Tavily 1순위

에이전트 검색 — 후보 URL 발견

Brave 보조

자체 인덱스·freshness

※ 검색 1위 ≠ 정답

존재·위치만 발견. 권위·진정성은 여기서 판단 ✕

▼ 승격(Promote) — Source Policy · 공식성 · 시점 · ①②와 일치 검증 통과분만



② 권위 계층 (Authority) — "결론 근거가 되는 곳"

국세청 · 기획재정부 · 법제처(국가법령정보) · 조세심판원 · 대법원/법원 공식 원문

✓ 공식 원문 URL·발행기관·retrieved_at·content_hash 확보

✓ 법령(①)·내부RAG(②)와 대조해 진정성·일치 확인 WEB-010


⚠ 미승격 웹 자료는 결론 근거 불가 — "참고·동향"으로만 표기

🚫 가장 중요한 규칙

검색 API가 상위로 올린 결과라도, 공식 원문으로 승격되지 않으면 결론 근거 0건입니다. "검색 1위 = 정답"은 이 설계에서 금지합니다. WEB-002 · WEB-011

도식 ② — Source Policy 이중 필터 (검색 전 + 검색 후)

출처 정책을 질의 단계뿐 아니라 검색 후에도 적용합니다. 검색 API는 질의와 무관하게 **mirror·블로그·구버전**을 끼워 반환할 수 있기 때문입니다.



✅ 허용 (우선·가중)

- 국세청 · 기획재정부 · 조세심판원
- 법제처(국가법령정보) · 대법원/법원
- 각 기관 공식 보도자료

✕ 배제 / 저신뢰

- 블로그 · 카페 · 광고성 세무 콘텐츠
- 출처불명 · 작성자 불명
- 미러 · 요약 재가공 · 구버전 캐시

🚫 Codex 핵심 — 검색 전 제한만으론 부족

검색 API가 허용 도메인 밖의 **mirror·요약·구버전**을 끼워 반환할 수 있으므로, 원문 추출 후 도메인·공식성·시점을 재검증해 탈락시킵니다. 미통과 결과는 결론에서 배제됩니다. WEB-002 · WEB-004 · WEB-007

도식 ③ — 웹 리서치 파이프라인 8단계

쟁점이 들어와 '결론 근거 후보'가 되기까지 8단계. 검색은 **중간의 한 단계**일 뿐, 앞뒤로 정책(②⑤)과 검증(⑥⑦⑧)이 감쌉니다.



도식 ④ — 검색 벤더 선택 (ADR)

어떤 검색 도구를 왜 쓰고, 무엇을 왜 뺐는지 의사결정을 기록(ADR)했습니다. 발견 도구는 여럿, 권위는 공식 커넥터로 확보합니다.

소스	역할	비고 (선택·제외 사유)
Tavily 1순위	에이전트 검색 (Discovery)	<code>include_domains</code> 로 공식출처 제한 · <code>time_range/topic</code> 활용 · <code>advanced=2 credits</code> (관련성 ↑·비용 ↑), <code>basic=1</code>
Brave Search 보조	보조 검색 (Discovery)	자체 인덱스· <code>freshness</code> · <code>site/filetype</code> 연산자 · LLM context endpoint
공식소스 커넥터 권위	권위 확보 (Authority)	국세청·법제처·조세심판원 직접 연계/스크래핑(법·기술·라이선스 허용 범위). 검색API 공백(동적페이지·PDF·구 예규·기본통칙) 보완
Google Custom Search 제외	제외	신규고객 차단·2027 전환 → ADR로 제외 사유 문서화 + recall 마일스톤에서 재검토 WEB-010

⚠ Codex 보강

Tavily/Brave는 **discovery**, 권위는 공식 커넥터입니다. 검색API가 **stale·비공식·재가공** 결과를 상위로 줄 수 있으니 **"검색 1위 = 정답" 금지**.

💡 왜 ADR로 남기나

감사조서에 **"왜 이 절차를 택했나"**를 남기는 것과 같습니다. 파트너가 **"Google은 왜 안 썼나?"**라고 물으면 **문서로** 답할 수 있어야 합니다.

도식 ⑤ — 한국어 세법 Query Expansion (검색어 확장)

일반 검색은 한국 공식자료를 잘 못 찾습니다. 법령명·조문번호 형식·약칭·기간 표현을 여러 형태로 확장해야 공식 원문에 적중합니다.

 **입력 (예시 · 가상 시나리오)** 쟁점 = "2024 귀속 접대비 한도초과 손금불산입" · 세목 = 법인세 · 귀속연도 = 2024

확장 축	한 표현으로는 놓치는 것	확장 예시
명칭 변형 ★	"접대비"만 검색 → 2024 개정 후 공식문서('기업업무추진비')를 놓침	접대비 ↔ 기업업무추진비(현 명칭) <u>동시</u> 질의
조문번호 형식	"제25조"만	법인세법 제25조 / 법인세법 25조 / 법25① / 시행령 제○○조
정식명칭·약어	"법인세법 시행령"만	법인세법 / 법인령 / 법령 약칭
기관·서식	본문만	국세청 보도자료 · 기재부 보도참고자료 · 서식명
기간/연도	"한도"만	2024 귀속 · 2024 사업연도 · 개정 시행일

 **왜 핵심인가 — 실제 사례**
접대비는 2024년부터 '기업업무추진비'로 명칭이 바뀌었습니다. 검색어 한 표현만 쓰면 정작 공식 원문을 놓쳐 "자료가 없다"는 잘못된 결론에 이를 수 있습니다. query expansion이 이 함정을 막습니다. WEB-008

회계사 포인트
실무에서 예규를 찾을 때 옛 명칭·새 명칭·조문번호·서식명을 두루 넣어보는 그 습관을 전산화한 것입니다. 명칭 개정·약칭을 모르면 공식 자료를 놓친다 — 이게 한국 세법 검색의 핵심 난점입니다.

도식 ⑥ — SourceSnapshot: 찾은 근거를 '시점·해시'로 박제

snippet만 쓰지 않고 원문 페이지를 추출해, 언제·어디서·무엇을 봤는지 메타와 함께 저장합니다. PDF·HWP·스캔본은 OCR로 본문을 확보합니다.

필드	의미	회계사 비유
url	원문 주소	조서 출처
canonical_title	정규 제목	문서 표제
publisher	발행기관 (국세청·기재부 등)	발행처
published_date	발행일	문서 일자
effective_date	적용시점 (가능 시)	시행일
retrieved_at	조회 시각	입수일
extraction_method	추출방식 (HTML/PDF/HWP/OCR)	입수 경로
content_hash	본문 해시	원본 무결성 봉인
official	공식 여부 플래그	증거능력 표시

⑥ Source Scoring — 웹 소스 내부 점수

후보별 점수 신호 (소스 간 가중혼합이 아니라 ③채널 내부 정렬)

- 공식성 · 최신성 · 쟁점 관련성
- 법적 권위 · ①②(법령MCP·내부RAG)와의 일치

⚠️ **최신성 ≠ 적용시점 유효성**


두 점수를 분리 저장합니다. "가장 최근 게시물"이 곧 "그 사업연도에 유효한 근거"는 아닙니다. WEB-012

💡 **왜 URL이 아니라 스냅샷 객체인가**

링크는 나중에 바뀌거나 사라집니다. 발행일·조회시각·해시까지 박아두면 "언제·무엇을 보고 판단했는지"가 재현됩니다. = 02_출처의 소스객체·시점 원칙.

도식 ⑦ — 충돌 탐지 & 승격 (Conflict → Promote)

웹 결과가 법령MCP(①)·내부RAG(②)와 다르면 평균내지 않고 ConflictFlag로 표시, 결론을 보류합니다. 검증을 통과한 것만 권위 소스로 승격합니다.



⚠ 충돌 시 — 단정 금지

평균·혼합 금지. 웹이 최신이라도 법령 원문과 다른 따라가지 않고 회계사 검토항목으로 넘깁니다(08_환 각 방 지). 미해소 충돌은 사람(HITL)에게. WEB-006

✅ 승격 검증 조건 WEB-011

- 공식 원문 URL·발행기관
·retrieved_at·content_hash
- ①법령 / ②RAG와 대조해 일치·진정성 확인
- 스니펫·재가공본만으론 승격 ×
- 미승격은 "참고·동향"으로만 표기

💡 왜 '보류'가 안전인가

웹이 최신이라고 법령 원문과 충돌하는데 따라가면 위험합니다. "최신 = 옳음"이 아니라 시점 유효성·권위로 따져야 합니다. 단정 대신 보류·검토가 자문 리스크를 줄입니다.

비개발자를 위한 전문용어 사전

웹 리서치에 자주 나오는 기술 용어를 회계사 눈높이로 한 줄씩 풀었습니다.

Query Planner

검색 설계

쟁점·세목·귀속연도·법령 키워드로 **검색어를 설계**하는 단계. 검색의 시작점.

Query Expansion

검색어 확장

같은 뜻을 **조문번호 형식·약칭·정식명칭·기간 표현**으로 여러 형태 확장. 한국 공식자료 적중률을 높임.

Source Policy

출처 정책

어떤 출처를 근거로 **인정/배제**할지 정한 기준표. **검색 전·후 이중** 적용.

Discovery

발견

검색으로 **'어디를 볼지'**를 찾는 발견 단계. 결과는 **단서일** 뿐 근거가 아님.

Authority Source

권위 소스

결론 근거가 될 수 있는 **공식 원문**(국세청·법제처·조세심판원·법원 등).

SourceSnapshot

소스 스냅샷

찾은 원문을 **URL·발행일·조회시각·해시**와 함께 박제한 저장 객체. 재현성의 토대.

Source Scoring

소스 점수

웹 소스 **내부**에서 공식성·최신성·관련성·권위·일치로 매기는 점수. 소스 간 가중혼합 아님.

Promotion

승격

검증을 통과한 웹 후보를 **권위 소스객체로 올려** 결론 근거로 인정하는 절차.

ConflictFlag

충돌 표시

웹이 법령·내부RAG와 **충돌함**을 표시해 결론을 **보류**하는 플래그. 평균·혼합 금지.

retrieved_at

조회 시각

그 자료를 **'언제 조회했는지'**. 시점·재현성의 핵심 (발행일과 다름).

SourceAnswer

소스별 독립 답변

①②③ 각 채널이 **따로 낸 완결 답변**. 웹 리서치는 ③번을 책임.

흔한 오해 8 — "이렇게 말하면 틀립니다"

웹 리서치를 소개할 때(면접·포트폴리오) 자주 빠지는 함정입니다. 오른쪽이 정확한 설명입니다.

#	✗ 이렇게 말하면 틀림	✓ 정확히는	근거
1	"검색 1위가 정답이다"	단서일 뿐. 공식 원문으로 승격돼야 근거.	WEB-011
2	"웹 리서치 = 답변 생성기"	최신 공식근거 수집기. 답은 종합 단계.	§11
3	"블로그도 설명 좋으면 근거"	배제·저신뢰. 비공식 결론 근거 0건.	WEB-004
4	"검색 전 도메인 제한이면 충분"	검색 후 mirror·구버전·요약도 재필터.	WEB-007
5	"최신 게시물이 더 좋음"	최신성과 적용시점 유효성은 별도.	WEB-012
6	"검색 API가 공식성 보장"	discovery 도구일 뿐. Source Policy가 검증.	WEB-002
7	"검색어 한 표현이면 충분"	한국어 query expansion 필요.	WEB-008
8	"Law MCP와 충돌해도 웹이 최신이면 따름"	단정 금지. 검토항목으로 보류.	WEB-006

한 문장으로 안전하게 소개하려면

"웹 리서치는 Tavily-Brave로 단서를 찾되, 국세청·기재부·법제처 공식 원문 승격분만 근거로 쓰고, 법령과 충돌하면 단정하지 않고 보류하는 최신근거 수집 장치입니다."

왜 이 페이지가 중요한가

파트너·면접관은 "AI가 검색해서 다 알려준다"는 과장을 가장 경계합니다. 오히려 발견과 권위를 구분하고 한계를 통제하는 것이 감사 배경 회계사의 강점으로 읽힙니다.

이 장을 왜 이렇게 썼나 — 핵심 메시지 3

01 인터넷 '답변기'가 아니라 "최신 공식근거 수집·검증 채널"이다

웹은 개정 동향·신규 예규·보도자료 같은 최신성을 보완하는 ③번 채널입니다. 답을 만드는 게 아니라 공식 원문을 찾아 검증해 독립 답변(SourceAnswer)을 만들 뿐, 결론은 종합·회계사 몫입니다.

02 검색 API는 '발견용', 결론 근거는 '승격된 공식 원문만'

Tavily·Brave는 **discovery**일 뿐. 결론 근거가 되려면 공식 원문 URL·발행기관·조회시점(retrieved_at)·content_hash를 갖추고 법령·내부RAG와 대조돼야 합니다. "검색 1위 = 정답"은 금지.

03 충돌 시 단정하지 않고 ConflictFlag로 보류한다

웹이 법령(①)·내부RAG(②)와 다르면 평균내지 않고 충돌을 표시해 결론을 보류, 회계사 검토(HITL)로 넘깁니다. "최신=옳음"이 아니라 시점 유효성·권위로 판단합니다.

면접 한 줄

"TIW 웹 리서치는 Tavily·Brave로 단서를 찾되 국세청·기재부·법제처 공식 원문 승격분만 SourceAnswer 근거로 쓰고, 충돌 시 결론을 보류하는 최신근거 수집 장치입니다."