

환각 방지 · 인용 검증 쉽게 읽기

"근거 없으면 결론 없다" — 답이 사용자에게 가기 전 통과하는 5개 검문소

docs / 08_환각방지_인용검증.md → 비개발자(KICPA)용 도식 해설

🛡️ 5개 검증 게이트 (G1~G5)

🔍 인용 4중 검사 · 존재·버전·pinpoint·지지(entailment)

🚩 위반 시 점수 상한(하드게이트)

작성 · 신현우 (KICPA, 2년차)

목적 · 딜로이트 안진 Business Tax 지원 / 포트폴리오

문서 · 법인세 자문 보조 AI 설계서 — 환각방지·인용검증 章 해설본

날짜 · 2026-06-28

30초 요약 — 이 문서(08)가 뭐죠?

한 문장: AI가 "그렇듯하게 지어내지 못하도록" 막는 안전장치 묶음입니다. 세무에서 환각(없는 근거를 지어냄)은 치명적이라, 답변은 5개 검문소(게이트)를 모두 통과해야만 사용자에게 갑니다. 이 章이 "감사로 검증을 체화한 회계사"의 정체성이 기능으로 구현되는 곳입니다.

① 무엇을 담나

5개 검증 게이트(계산·인용·충돌·시점·사람), 인용 검증 규칙, 충돌 해소표, 하드 게이트 점수 상한.

② 왜 중요한가

"그렇듯한 최신 오답(fluent wrong)"이 세무에선 가장 위험. 근거·시점·지지를 강제해 이를 차단합니다.

③ 핵심 원칙

무근거 결론 금지 · AI는 결론을 내리지 않음(선택지·근거·보류까지) · 결정과 서명은 회계사(HITL).

회계사의 직관으로 번역하면 — 3가지 비유

비유 1 · 감사조서의 「근거 없는 결론 금지」 원칙을 시스템으로

감사에서 **증빙 없는 결론**은 적습니다. 증빙이 없으면 단정하지 않고 **검토항목**으로 넘기죠. 이 章은 그 원칙을 코드로 강제합니다 — 모든 세무·법적 단정은 **소스객체 인용**을 가져야 하고, 없으면 결론을 못 냅니다. (HALU-001)

비유 2 · 인용 검증 = 조문번호 적기가 아니라 "그 조문이 실제로 그 말을 지지하는지" 대조

감사조서에 **참조번호만** 달았다고 끝이 아니라, 그 증빙이 **실제로 결론을 뒷받침하는지** 확인하죠. 인용도 마찬가지로 — 개수가 아니라 **지지(entailment)** 여부를 봅니다. 인용했는데 그 말을 지지 안 하면 거부/수정. (HALU-003)

비유 3 · 충돌 표면화 = 평균 내지 않고 이견을 표시해 파트너 리뷰로

회사 설명·외부조회·계약서가 **서로 다르면** 평균을 내지 않습니다. **이견을 그대로 드러내** 상위 검토로 올리죠. 세 근거(법령·실무서·웹)가 충돌하면 **단정 금지** → **회계사 검토항목**으로 승격합니다. (HALU-005)

⚠ 오해 주의

"출처(RAG)만 붙이면 환각은 끝"이 아닙니다. 출처를 붙인 뒤에도 **인용이 진짜 지지하는지·시점이 맞는지·충돌하는지**를 따로 검사하는 게이트가 있어야 합니다. 이 章이 바로 그 검사입니다.

도식 ① — 답이 거치는 5개 검문소 (검증 게이트)

답변은 만들어지자마자 나가지 않습니다. 계산이 맞나 → 인용이 진짜 지지하나 → 출처가 충돌하나 → 시점을 아나 → 마지막은 회계사인가, 다섯 관문을 통과해야 합니다. 핵심은 소스별로 한 번(G1·G2), 종합에서 또 한 번(G3~) 검사한다는 점입니다.

① 법령 · ② 내부RAG · ③ 웹 — 각 SourceAnswer마다 개별 적용

G1

계산 검사

산식을 Ground Truth와
대조 · 불일치 빨간 깃발

G2

인용 검증

존재·버전·pinpoint
·지지(entailment)·권한

▼ 3소스를 claim(원자 단위 주장)으로 종합 ▼

G3

충돌 표면화

소스 충돌을 claim 단위로
· 평균 금지 → 검토항목

G4

시점 · 보류

시점불명·근거부족 시
단정 대신 되물음(abstain)

G5

회계사 검토(HITL)

검토항목 자동생성
→ 승인 · 서명

📄 왜 두 번 검사하나

G1·G2는 각 소스의 답(SourceAnswer)에 개별 적용하고, G3 종합 단계에서 claim 단위로 충돌과 추적(lineage)을 재검증합니다. 한 소스가 인용을 날조하면 그 소스를 캡하고 종합에 경고를 전파합니다.

HALU-013 / HALU-014

💡 회계사 포인트

감사의 preparer → reviewer → partner 다단계 검토와 같습니다. 답이 고객에게 가기 전 여러 검문소를 거치고, 모르면 통과시키지 않습니다.

도식 ② — G1 계산 검산: 어디까지 "정답"이라 말할 수 있나

이 AI의 감사 DNA가 드러나는 곳. 단, "세법은 정답이 정해져 있다"는 과한 말입니다. 계산엔진은 산식은 검증하지만 사실인정·법적 평가는 못 합니다. 이 둘을 정직하게 구분하는 게 차별점입니다. (HALU-011)

✅ 산식 검증 가능 (Ground Truth 대상)

접대비 한도 · 감가상각비 · 기부금 한도 · 지급이자 손금불
산입 · 세액공제 산식 · 인정이자 계산

⚠️ 사실인정·법적 평가 필요 (계산으로 단정 X)

특수관계 여부 · 업무무관성 · 시가/인정이자율 적용 판단 · 증빙 적격
성 · 손금 귀속

처리: src/ 계산엔진과 자동 대조 → 불일치 시 빨간 깃발
(HALU-002)

처리: 회계사 판단(HITL) — 계산엔진이 단정하지 않고 검토항목으로

"가정값"은 정직하게 표시

시가처럼 사실판단에 의존하는 입력은 결과에 그냥
박지 않고 "가정값"으로 표시하고, 가정이 바뀌면 결
과도 바뀔을 고지합니다. 계산 로그를 저장해 재현 가
능하게.

차별점

법률 AI는 보통 해석만 검증합니다. TIW는 검증 가능
한 계산까지 검산하되, 범위를 정직하게 한정합니다
— "계산은 맞췄지만 시가 판단은 회계사 몫"이라고
분명히 말합니다.

💡 회계사 포인트

세무조정 검토에서 한도 계산은 기계가, 사실판단은 사람이 하는 그 경계를 그대로 시스템에 새겼습니다. "AI가
다 맞춘다"가 아니라 "무엇까지 자동으로 보증되는지"를 명확히 하는 것이 신뢰의 출발입니다.

도식 ③ — G2 인용 검증: 인용을 "5가지"로 뜯어본다

인용은 달기만 하면 끝이 아닙니다. 각 주장 문장의 인용(Citation)을 다섯 항목으로 검사합니다. 특히 **지지(entailment)**가 핵심 — 인용 개수가 많은 것과 그 인용이 실제로 그 말을 뒷받침하는 것은 다릅니다.

검사	무엇을 보나	위반 시
① 존재 existence	인용한 소스객체가 실제 존재 하는가 (날조 아님)	하드게이트 60 인용 날조
② 버전·시점	시행일 버전 (ProvisionVersion)을 가리키고 적용시점(applicable_basis)과 일치하는가 version	상한 65 시행일 오류
③ pinpoint	조/항/호·문단·페이지까지 특정 했는가 ("법인세법에 따라" 수준은 미달)	인용 부족 → 보강 요구
④ 지지 ★ entailment	인용 원문이 그 주장을 실제로 지지 하는가 (개수 아님)	비지지 인용 → 수정/거부
⑤ 출처 권한 license	무권한·전직장 출처를 인용하지 않았는가	하드게이트 0 무권한 인용

🚫 가장 중요한 한 가지 — 지지(entailment)

법조문을 그럴듯하게 갖다 붙였지만 실제로는 그 결론을 지지하지 않는 경우가 환각의 단골입니다. 그래서 "인용이 있다"가 아니라 "그 인용이 이 주장을 뒷받침하는가"를 봅니다. = 감사조서의 참조가 결론을 실제로 입증하는지 확인하는 일.

💡 회계사 포인트

인용의 존재·버전·위치·지지·권한은 감사의 **실재성·기간귀속·정확성·권리의무** 같은 경영진 주장(assertions) 검증과 닮았습니다. 하나라도 깨지면 그 결론은 못 나갑니다.

도식 ④ — G3 충돌 표면화: 3소스를 claim 단위로 맞춰본다

세 근거가 각자 완결된 답을 낸 뒤, 답을 **claim**(원자 단위 주장)으로 쪼개 일치/충돌/침묵을 표시합니다 (ClaimAlignment). 평균·다수결 금지. 충돌하면 단정하지 않고 검토항목으로 올립니다.

① 법령

Korean-law-MCP

독립 답변 A

② 내부 RAG

실무서·예규

독립 답변 B

③ 웹

최신 공식자료

독립 답변 C

▼ **claim 단위로 일치 ✓ / 충돌 ⚡ / 침묵 ◌ 매핑 ▼**

양상불 엇지 케이스 — 답이 갈릴 때 어떻게 처리하나

상황	처리	표시
한 소스 침묵/공백	불일치로 보지 않음 · 나머지로 진행 + 커버리지 캡. 침묵 소스가 권위면 confidence ↓ · HITL	status=SILENT "③ 웹 근거 없음"
3자 모두 불일치	claim별 해소 불가 시 종합의견 보류 + 위험도별 검토 escalate	소스별 입장 각각 + "종합 보류"
2 합치 · 1 충돌	다수결 × → 권위 먼저 : 소수라도 상위 권위·유효 최신법이면 소수 채택	다수/소수·권위비교·"반대 근거"
①법령 부재, ②③ 합치	비권위적 합의 : 실무·웹이 법령을 대체 못 함 → 실무가이드로만, confidence 캡·고위험 HITL	"법령 원문 근거 미확보" 명시

💡 핵심

종합의견이 **보류(abstain)**하더라도 소스별 답변은 그대로 보여줍니다. "확신에 찬 오답"보다 "**여기까지는 확실, 이 지점은 갈림**"이 회계사에게 훨씬 유용합니다 — 방어가능성과 유용성을 동시에.

도식 ⑤ — 충돌 해소 결정표: LLM 재량이 아니라 "규칙"으로

충돌을 AI가 기분대로 푸는 게 아니라, 정해진 규칙(rules/)으로 처리하고 결정 결과를 로그로 남깁니다(재현·감사 가능). 판단 입력은 권위순위 · 시점 유효성 · 사실관계 동일성 · 출처유형입니다. (HALU-012)

상황	결정
법률 vs 웹/실무서 불일치	법률 채택, 웹/실무서는 참고로 강등
법률 vs 예규/판례(해석)	법률 문언 + 해석을 함께 제시 (예규는 구속력 한계 표시)
같은 조문의 다른 시행일 버전	적용시점에 유효한 버전 채택, 타 버전 배제
예규 vs 예규 (신·구)	supersede·발행일로 유효본, 사실관계 동일성 확인
사실관계 다른 예규를 끌어옴	원용 불가 표시 → 검토항목
해소 불가 (권위·시점 동급)	단정 금지 → 회계사 검토항목 (숨기지 않고 그대로 노출)

이 표의 의미

이것이 "법령 > 시행령 > 예규·판례 > 실무서 > 웹"이라는 권위 위계를 코드로 강제하는 지점입니다. 소스 간 산술 가중(50/30/20)으로 섞는 게 아니라, 충돌이 났을 때 권위와 시점으로 결정합니다.

💡 회계사 포인트

감사에서 증거 간 우선순위(외부확인 > 내부서류 > 구두답변)를 정해두듯, 세무 근거의 우선순위를 미리 규칙화해 두고 그 적용 결과를 남깁니다. 자의적 판단을 배제하는 장치입니다.

도식 ⑥ — G4 신뢰도 분리 + 보류(abstain)

두 가지 신뢰도를 합치지 않고 따로 저장합니다. 유창하지만 근거가 약한 답("fluent wrong")을 걸러내기 위해서입니다.

retrieval_confidence

"근거가 있는가?"

top 재정렬 점수 · 근거 충분성 · 적용시점 유효성 충족 · 인용 지지(entailment) 비율로 계산.

generation_confidence

"답이 근거 위에 서 있는가?"

인용 커버리지(주장 중 인용된 비율) · 충돌 없음 · 계산 플래그 없음으로 계산.

⊗ 게이트 규칙 — 유창함에 속지 않는다

retrieval_confidence가 임계 미만이면, **generation_confidence**가 아무리 높아도(=말이 매끄러워도) 무조건 보류(abstain). 근거가 약하면 매끄러운 문장은 오히려 위험 신호입니다. 두 점수와 보류 사유를 로그로 남깁니다.

(HALU-006/007)

보류(Abstention) = 되물음

시점 불명·근거 부족·자료 결손이면 **결론 대신 질문**합니다. 예: "어느 사업연도 기준인가요?", "○○ 자료가 없어 추정입니다."

보류는 감점이 아니라 가점

채점표에서 **abstention credit**으로 보상합니다(09). 모르면서 단정하는 것보다, 모른다고 되물는 편이 낫다는 감사의 직업적 회의주의를 점수로 새겼습니다.

도식 ⑦ — 하드게이트(점수 상한) + G5 회계사 검토

여기면 즉시 점수가 깎이는 절대 기준입니다. 아무리 잘해도 이 위반이 있으면 상한을 못 넘습니다(채점표 09와 연결).

위반	게이트	점수 상한
인용 날조 (존재하지 않는 조문·예규)	G2	60
테넌트/고객데이터 누수	보안	0
무권한·전직장 데이터 인용/사용	G2/보안	0
고위험 조언에 회계사 검토경고 누락	G5	70
출처·모델·프롬프트·도구 trace 재현 불가	재현성	75
핵심 결론의 법령 시행일 오류	G2/G4	65
법령원문 필요한데 웹만으로 단정	G3	검토항목 강제

G5 — 회계사 검토항목 자동생성 (HITL)



▼ 자동으로 "회계사 검토 필요사항" 리스트 생성 → 승인/반려·잠금·서명

💡 고객 전달본 ≠ 내부 메모

전략 리스크·과세논리 같은 내부 검토용 내용은 고객 전달본과 분리됩니다. 각 게이트 결과는 Review/ReviewerDecision에 기록되어 "누가 무엇을 승인했나"가 남습니다.

비개발자를 위한 전문용어 사전

이 문서에 자주 나오는 용어를 회계사 눈높이로 한 줄씩 풀었습니다.

환각 Hallucination	AI가 없는 근거를 지어내거나 , 인용이 주장을 지지하지 않는데 그럴듯하게 답하는 오류. 세무에선 치명적이라 게이트로 차단.
지지 entailment	인용 원문이 그 주장을 실제로 뒷받침 하는가. 인용 개수가 많다는 뜻이 아님 . 환각 검증의 핵심.
검증 게이트 Verification Gate	답변이 사용자에게 가기 전 통과해야 하는 검사 단계 . 계산·인용·충돌·시점·회계사 검토(G1~G5).
Ground Truth 계산 정답	한도·산식처럼 객관적으로 검산 가능한 기준값. 계산엔진이 자동 대조. (사실판단은 대상 아님)
confidence 신뢰도	답변 신뢰 점수. 검색 신뢰도(근거 있나) 와 생성 신뢰도(근거 위에 섰나) 를 분리 저장.
앙상블 Ensemble	법령·내부RAG·웹이 각각 독립 답변을 낸 뒤 claim 단위로 비교하는 방식. 평균·다수결 금지 .
claim 원자 단위 주장	답을 더 못 쪼개는 최소 주장 단위 . 소스끼리 이 단위로 일치/충돌/침묵을 대조.
소스 침묵 SILENT	특정 출처가 관련 근거를 못 낸 상태. 불일치로 보지 않되 커버리지 갭 으로 표시.
abstain 보류 · 되물음	근거 부족·시점 불명이면 결론을 내지 않고 되물거나 보류 . 채점에서 가점.
하드게이트 Hard Gate	인용 날조·무권한 출처 등 발생 시 점수 상한 또는 0점 을 강제하는 절대 차단 규칙.
HITL Human-In-The-Loop	사람(회계사)이 반드시 끼어드는 관문 . 최종 결정·서명은 AI가 아니라 사람.
fluent wrong 유창한 오답	문장은 매끄러운데 근거가 약한 답. 가장 위험. 검색 신뢰도가 낮으면 차단(abstain).

흔한 오해 — "이렇게 설명하면 틀립니다"

이 모듈을 소개할 때 자주 빠지는 함정입니다. 왼쪽처럼 말하면 설계 의도를 정반대로 전달하게 됩니다.

#	❌ 이렇게 말하면 틀림	✅ 정확히는	근거
1	"AI가 최종 세무 결론을 내준다"	결정·서명은 회계사(HITL). AI는 근거·선택지·검토사항을 제시.	HALU-008
2	"인용만 있으면 검증은 끝"	존재·버전·pinpoint·지지(entailment)를 모두 검사해야 함.	HALU-003
3	"세 소스 중 다수가 같으면 다수결로 확정"	평균·다수결 금지. 권위·시점·사실동일성으로 판단.	HALU-005/012
4	"계산엔진이 세법 판단 전체를 검증"	산식만 검증. 사실인정·법적평가는 검토항목으로 구분.	HALU-011
5	"답이 유창하면 신뢰도 높다"	검색 신뢰도 낮으면 유창해도 보류(abstain).	HALU-006/007
6	"출처 없는 종합 문장도 자연스러우면 OK"	추적 불가한 종합 claim은 최종 표시 차단.	HALU-014
7	"RAG가 있으면 환각은 해결"	RAG + 인용검증·시점·claim정합·충돌표시·HITL을 함께 요구.	G1~G5

한 문장으로 안전하게 소개하려면

"답을 내기 전에 계산·인용·충돌·시점·회계사의 다섯
검문소를 통과시키고, 모르면 단정하지 않고 되묻는
안전장치입니다."

왜 이 페이지가 중요한가

파트너·면접관은 "AI가 환각을 안 한다"는 단언을 가
장 의심합니다. 오히려 "어떻게 환각을 잡아내는
가"의 구체적 장치를 보여주는 게 감사 배경 회계사
의 강점입니다.

이 문서를 왜 이렇게 썼나 — 핵심 메시지 3

01 근거 없는 세무·법적 단정은 시스템상 허용되지 않는다

모든 주장은 **소스객체 인용**을 가져야 하고, 없으면 결론을 못 냅니다. "근거 없으면 결론 없다"를 **게이트로 강제** — 감사의 직업윤리를 코드로 옮겼습니다.

02 인용은 존재뿐 아니라 시행일 버전·실제 지지까지 검증한다

조문번호를 단다고 끝이 아닙니다. 그 인용이 적용시점에 맞는 버전인지, 그 주장을 실제로 지지하는지 (**entailment**)까지 확인합니다.

03 충돌하거나 모르면 숨기지 않고 보류·되물음·회계사 검토로

소스가 충돌하면 평균 내지 않고 **이견을 표시**, 시점이 불명하면 **되물고**, 마지막은 **회계사 검토(HITL)**로 올립니다. 보류는 감점이 아니라 가점.

면접 한 줄

"감사는 '틀린 걸 잡아내는' 일입니다. 그래서 이 AI는 답을 내기 전에 **다섯 개의 검문소**를 통과시킵니다 — 계산이 맞나, 인용이 진짜로 그 말을 지지하나, 출처들이 충돌하나, 시점을 아나, 마지막은 회계사인가. 모르면 **단정하지 않고 되물습니다**. 환각이 치명적인 세무에서, '근거 없으면 결론 없다'를 게이트로 강제했습니다."

이 후과 맞물리는 문서

02 출처·시점

인용 버전·
적용시점

05 RAG · 06 웹

검색 근거
(소스별 답변)

04 ERD

ConfidenceScore
ClaimAlignment

09 채점표

하드게이트
점수 상한

Tax Intelligence Workspace (TIW) · 법인세 자문 보조 AI 설계서

본 해설본은 docs/08_환각방지_인용검증.md의 비개발자용 도식 요약입니다 · 정본은 원문을 따릅니다 · 2026-06-28